



**UNIVERSIDAD AUTONOMA DEL
CARMEN**

MAESTRO(A):
sa

ALUMNO:

GERARDO GOMEZ PEREZ.

MATERIA:
DISEÑO DE INTERFACES

FACULTAD:
INGENIERIA EN SISTEMAS
COMPUTACIONALES.

Contenido

1. Introducción.....	3
2. Árbol ID3 (elaboración propia)	3
3. Árbol J48 (Weka)	3
4. Comparación entre ambos algoritmos	4
5. Similitudes y diferencias.....	4
6. Conclusión.....	5

Comparación de Algoritmos de Árboles de Decisión

ID3 aplicado manualmente vs. J48 (C4.5) en Weka — Dataset Iris

1. Introducción

Este reporte presenta la aplicación del algoritmo ID3 (Iterative Dichotomiser 3) sobre el conjunto de datos Iris, previamente discretizado en categorías (Chico, Mediano, Grande) para cada atributo, y lo compara con el resultado obtenido al ejecutar el algoritmo J48 (implementación de C4.5) sobre el mismo dataset en su forma original (valores numéricos continuos) utilizando el software Weka.

El objetivo es evaluar si ambos algoritmos, partiendo de estrategias distintas, convergen hacia conclusiones similares sobre qué atributos son más relevantes para clasificar las especies de la flor Iris.

2. Árbol ID3 (elaboración propia)

A partir de los datos categorizados, se calculó la entropía global del conjunto (1.585) y la ganancia de información de cada atributo. El atributo con mayor ganancia fue Ancho_Petalo (1.3784), seleccionado como raíz del árbol. El proceso se repitió recursivamente sobre cada subconjunto, aplicando una poda por error de entrenamiento: se colapsa una división en una sola hoja cuando el error de clasificar por mayoría es igual o menor que la suma de errores de continuar dividiendo.




Figura 1. Árbol ID3 podado, elaborado a partir de los datos categorizados.

3. Árbol J48 (Weka)

Como contraste, se ejecutó el algoritmo J48 (-C 0.25 -M 2) en Weka sobre el dataset Iris original (valores numéricos), con validación cruzada de 10 particiones (10-fold cross-validation).




Figura 2. Árbol J48 generado por Weka Classifier Tree Visualizer.

Resultados de evaluación (10-fold cross-validation):

- Instancias correctamente clasificadas: 144 (96%)
- Instancias incorrectamente clasificadas: 6 (4%)
- Kappa statistic: 0.94
- Root mean squared error: 0.1586

4. Comparación entre ambos algoritmos

Criterio	J48 (Weka)	ID3 (propio)
Atributo raíz	petalwidth (≤ 0.6 / > 0.6)	Ancho_Petalo (Chico/Mediano/Grande)
Tipo de dato	Numérico continuo, umbrales binarios	Categorico pre-discretizado en 3 bins
Criterio de selección	Gain Ratio (normaliza la ganancia por el número de valores del atributo)	Ganancia de Información pura
Nº de hojas	5	5
Nº de nodos totales	9 (4 internos + 5 hojas)	7 (2 internos + 5 hojas)
Poda	Pessimistic error pruning (parámetro -C 0.25)	Poda por error de entrenamiento (hoja vs. subárbol)
Evaluación	10-fold cross-validation → 96% de exactitud	Error de entrenamiento (resustitución) → ~97.3% (146/150)

5. Similitudes y diferencias

Similitudes:

- Ambos árboles llegan exactamente al mismo número de hojas (5) y seleccionan el mismo atributo dominante: el ancho del pétalo.

- Ambos separan perfectamente Iris-setosa del resto desde el primer nivel, y ambos dejan un pequeño margen de error irreducible (1 a 2 casos) al distinguir Iris-versicolor de Iris-virginica, reflejo de un solape real entre esas dos especies en el dataset.

Diferencias:

- El árbol ID3 propio es más compacto (7 nodos frente a 9) porque trabaja con atributos ya categorizados en 3 valores, permitiendo divisiones ternarias en un solo nodo; J48 trabaja con valores numéricos continuos y solo puede hacer divisiones binarias, por lo que necesita dos nodos encadenados de petalwidth para lograr un efecto equivalente.
- J48 utiliza Gain Ratio en lugar de Ganancia de Información pura, corrigiendo el sesgo de ID3 hacia atributos con muchos valores posibles.
- J48 fue evaluado con validación cruzada de 10 particiones (96% de exactitud), una estimación más honesta del desempeño en datos nuevos; el ID3 propio solo se evaluó con el error de entrenamiento (resustitución), lo cual tiende a ser optimista.

6. Conclusión

A pesar de partir de estrategias distintas —C4.5/J48 con atributos numéricos y poda basada en estimación de error pesimista con validación cruzada, frente a ID3 con atributos discretizados y poda por error de entrenamiento—, ambos algoritmos convergen hacia una solución prácticamente equivalente: el mismo atributo raíz, la misma cantidad de hojas, y el mismo pequeño margen de error irreducible entre Iris-versicolor e Iris-virginica. Esto confirma que el ancho del pétalo es, sin duda, la variable más informativa del dataset Iris para la tarea de clasificación.